

Instituição Executora



Parceiro



Apoio



Residência Tecnológica

Análise de

Dados e IA

**Projeto SIBILA: Segmentação
Inteligente de Base para
Identificação de Limiar de Aceite**

Equipe: Emily Cavalcanti, Lívia Lorrani,
Marcelly Arcanjo, Rafael Moura , Thiago Malta



GESTÃO DE PROJETO

Bastidores e Metodologia Ágil

1.Divisão de Papéis

Engenharia e Dados:

Tratamento de nulos, variáveis temporais e feature engineering

Modelagem e métricas: Treino de Random Forest, busca de hiperparâmetros e validação.

Negócio e apresentação: validação de hipóteses e tradução para impacto em risco

2. Kanban no Trello

Fluxo Contínuo de Tarefas

 Backlog (Requisitos)

 A fazer

 Em Andamento

 Concluído (Pronto)

3.Ritmo e Ferramentas

Alinhamentos rápidos (*dailies*) para identificação de impedimentos

Ferramentas Utilizadas:

Trello

Python

Git/GitHub

0 Problema

Contexto

Seguradora do segmento empresarial precisa avaliar o nível de risco associado a clientes pessoa jurídica antes da formalização de contratos de seguros empresariais (coberturas como vendaval, danos elétricos e roubo ou furto de bens).

Impacto do problema

A incapacidade de identificar antecipadamente diferentes níveis de exposição ao risco dificulta a precificação correta e a tomada de decisões adequadas de subscrição, podendo gerar perdas financeiras.

Objetivo do desafio

Avaliar e classificar antecipadamente o nível de risco (probabilidade de ocorrência de sinistro) dos clientes, criando um escore que sirva como ferramenta de apoio à decisão (políticas de aceite, recusa ou revisão manual).

Entendimento dos Dados

Origem

*Base fornecida pela mentoria
(Trillia)*

Tamanho

*Há 32.868 registros e 103
atributos.*

Período

Janeiro/2019 a Dezembro/2021.

Principais características

Variáveis-chave: “Alvo” (Identifica se houve ou não sinistros)


Qualidade: Presença de outliers válidos e alta taxa de nulos (24-39%) além de dados “imaturos”.

Limitações: Dados de 2021 sofrem com falta de maturação (sinistros ainda não reportados).

Entendimento dos Dados

Taxa de dados ausentes

Variáveis de perfil corporativo e mercado regional concentram o maior volume de nulos (25% a 40%), exigindo técnicas específicas de imputação e agrupamento.



TOP 20 colunas com mais valores ausentes

Análises Exploratórias

Gráfico 1





Gráfico 2



Leitura dos gráficos

A queda nos sinistros em 2021 não é uma mudança real de risco, mas sim dados não maturados (sinistros ainda não reportados). Além disso, variáveis geográficas mostraram alto poder de separação de risco.

Solução

1 Estratégia adotada

Treinamento de um modelo de classificação (Random Forest) sobre dados históricos, gerando um score de risco por empresa que permite segmentar a carteira e antecipar o risco antes da emissão da apólice.


2 Ferramentas utilizadas

Python, Pandas e NumPy para manipulação de dados. Scikit-learn para o pipeline de preparação, modelagem (RandomForestClassifier) e métricas de avaliação. Matplotlib/Seaborn para as visualizações.


3 Arquitetura da solução

Dados brutos → preparação (ColumnTransformer) → modelo (RandomForestClassifier) → score de risco → faixas de decis.

Fluxograma da arquitetura



Demonstração



Principais Insights

- 1 *O grupo de maior risco sinistra quase 2x mais que a média da carteira!*
- 2 *Variáveis numéricas de dinâmica de mercado quase não importam sozinhas*
- 3 *2021 não ficou mais seguro, só ficou "imaturo"*
- 4 *O modelo erra o nível, mas acerta a ordem (a capacidade de separar risco não muda.)*
- 5 *De 14% a 56%: o score realmente separa risco (Separação monotônica evidente)*

Impacto para o Negócio

Quanto valor a solução gera?

11%

Melhora de Sinistralidade

Queda mínima de ~35% para ~31% recusando/reprecificando decil de maior risco

20%

Eficiência de Triagem

20% dos sinistros capturados revisando só 10% da carteira (grupo de maior risco)

4x

Diferenciação de risco para precificação

base concreta para prêmios diferenciados por perfil, não uma tarifa única para toda a carteira

Limitações

O que dificultou o projeto

1. *A ausência de maturação completa dos dados em safras recentes (2021) forçou um descarte considerável do volume de base para evitar enviesamento do teste.*
2. *Vazamento metodológico (Leakage) na seleção de variáveis que só foi percebido numa revisão posterior e corrigido.*
3. *Overfitting moderado ($KS > AUC$) mitigado mas não eliminado pelos hiperparâmetros.*

O que ainda precisa de validação

1. *O modelo usa um limite heurístico temporal. Faltou utilizar abordagens atuariais formais (como triângulos de run-off ou cálculo de IBNR) para corrigir as safras recentes.*
2. *O ponto de corte do Decil 10 é uma sugestão técnica: ele deve ser validado com o negócio para medir o impacto na perda da receita (prêmios que deixam de ser emitidos).*

Próximos Passos

CURTO PRAZO

Validar com a área atuarial o trade-off do ponto de corte (Recusar o Decil 10 vs Perder a receita dessas apólices).

MÉDIO PRAZO

Testar algoritmos mais complexos como XGBoost/LightGBM e aumentar o grid de busca de hiperparâmetros para refinar a precisão no "meio da tabela"

LONGO PRAZO

Implementar um cálculo atuarial de IBNR em conjunto com o modelo preditivo para que safras recentes também possam compor o período de treino do Random Forest.

Parcerias de Sucesso



Instituição Executora



Parceiro



Apoio



Residência Tecnológica

Análise de Dados e IA

Perguntas?

github.com/arcmarcelly/Projeto-Final-Residencia-Dados-IA

