

RESIDÊNCIA TECNOLÓGICA EM DADOS E IA

Relatório Técnico do Projeto Final

Sibila - Segmentação Inteligente de Base para Identificação de Limiar de Aceite

1 Resumo Executivo

1.1 Informações do Time

Equipe	2
Integrantes	Emily Cavalcanti, Livia Lorrani, Marcelly Arcanjo, Rafael Moura , Thiago Malta
Mentor	Nicola Pedulla
Empresa	Trillia
Desafio	Segmentação de risco patrimonial

1.2 Qual era o problema?

O desafio consistiu em avaliar e classificar antecipadamente o nível de risco de clientes pessoa jurídica antes da formalização de seguros empresariais, considerando a ocorrência de sinistros patrimoniais, como vendaval, danos elétricos e roubo ou furto de bens.

1.3 Como ele foi resolvido?

O problema foi tratado com Machine Learning supervisionado de classificação binária, utilizando a variável *ALVO* para representar a ocorrência ou não de sinistro. Foi desenvolvido um pipeline envolvendo exploração e preparação dos dados, tratamento de valores ausentes, seleção e transformação de variáveis, engenharia de atributos e divisão temporal da base. O algoritmo utilizado foi o *Random Forest Classifier*. A base possuía 32.868 registros e 103 atributos, sendo reduzida para 59 variáveis explicativas após a seleção. O modelo gera um score de risco entre 0 e 1, permitindo ordenar as empresas de acordo com seu risco relativo de sinistro.

1.4 Quais foram os principais resultados?

O modelo apresentou capacidade consistente de diferenciação e ordenação dos riscos, com *AUC-ROC* de 0,662 no treinamento e 0,656 no teste, além de *KS* de 0,349 no

treinamento e 0,246 no teste. A análise por decis demonstrou aumento consistente da taxa de sinistro conforme o score de risco aumenta, passando de aproximadamente 14% no grupo de menor risco para 56% no grupo de maior risco. O grupo de maior risco apresentou aproximadamente duas vezes a taxa média de sinistro da carteira, indicando potencial para apoiar estratégias diferenciadas de subscrição.

1.5 Qual o impacto esperado?

Espera-se que a solução contribua para melhorar a avaliação de risco, a precificação dos contratos e a eficiência operacional da seguradora, permitindo identificar previamente empresas com maior exposição a sinistros. O score pode apoiar ações como revisão manual de propostas, políticas de aceite e medidas preventivas, contribuindo para reduzir perdas financeiras e proteger a receita da companhia. O modelo deve ser utilizado como ferramenta de apoio à decisão, e não como mecanismo automático de aceite ou recusa.

2 Contexto do Negócio

2.1 Contexto do Desafio

O projeto está inserido no contexto do mercado de seguros empresariais, no qual a seguradora precisa avaliar o risco associado a clientes pessoa jurídica antes da formalização de contratos.

Nesse cenário, a capacidade de identificar antecipadamente diferentes níveis de exposição ao risco pode contribuir para decisões mais adequadas de subscrição e precificação.

A proposta do projeto é utilizar técnicas de análise de dados e Machine Learning para transformar informações disponíveis sobre as empresas em uma classificação de risco que possa apoiar o processo de decisão da seguradora.

2.2 Área responsável

A área responsável pelo problema está relacionada à operação de seguros empresariais, especialmente aos processos de subscrição, análise de risco, produtos e formalização de contratos.

2.3 Problema enfrentado

A seguradora enfrenta a dificuldade de classificar antecipadamente o risco de ocorrência de sinistros para clientes pessoa jurídica antes da emissão da apólice.

A ausência de uma classificação de risco adequada pode resultar em contratos com precificação incompatível com o nível de exposição apresentado pelo cliente, aumentando a possibilidade de perdas financeiras e dificultando a adoção de medidas preventivas.

2.4 Objetivos do desafio

2.4.1 Objetivo geral

Desenvolver uma solução de Machine Learning capaz de estimar o risco relativo de ocorrência de sinistros patrimoniais em empresas seguradas, utilizando informações disponíveis anteriormente à emissão da apólice, de forma a apoiar as decisões de subscrição, avaliação de risco e gestão operacional da seguradora.

2.4.2 Objetivos específicos

- Analisar as características e a qualidade dos dados disponíveis sobre empresas e seu contexto de mercado;
- Identificar variáveis com maior relação com a ocorrência de sinistros;
- Avaliar a existência de padrões temporais, incluindo possíveis alterações na distribuição dos dados e na relação entre variáveis e ocorrência de sinistros;
- Realizar o tratamento e a preparação dos dados para utilização em modelos de Machine Learning;
- Desenvolver novas variáveis por meio de técnicas de engenharia de atributos;

- Construir um modelo supervisionado de classificação capaz de gerar um score de risco entre 0 e 1;
- Avaliar a capacidade do modelo de diferenciar e ordenar empresas segundo seu risco relativo;
- Identificar um possível ponto de corte para direcionamento de propostas de maior risco para análise diferenciada;
- Avaliar a estabilidade temporal do modelo e suas limitações para utilização operacional.

3 Perguntas de Negócio

- É possível identificar, antes da emissão da apólice, empresas com maior probabilidade relativa de ocorrência de sinistro?
- Quais características das empresas e de seu contexto apresentam maior relação com a ocorrência de sinistros?
- Como a seguradora poderia utilizar o score para direcionar suas decisões de subscrição e reduzir sua exposição a perdas?

4 Base de Dados

Fonte	Base fornecida pela mentoria (Neurotech) CSV único: 32.868 registros, 103 colunas, jan/2019-dez/2021
Quantidade de registros	32.868
Quantidade de atributos	103
Período	Janeiro de 2019 a dezembro de 2021
Formato	CSV

5 Entendimento dos Dados

A base disponibilizada para o projeto contém informações estruturadas e anonimizadas relacionadas a empresas, características cadastrais, contexto de mercado e localização, além da variável *ALVO*, utilizada para representar a ocorrência de sinistro.

Inicialmente, a base apresentou 32.868 registros e 103 colunas. A variável *CNPJ* foi tratada exclusivamente como identificador anonimizado da empresa, não sendo utilizada como variável explicativa. O campo *ANO_MES* foi utilizado para estabelecer a ordenação temporal das observações e *ANO* foi derivado a partir dele.

Após a exclusão dos identificadores e da variável-alvo, foram identificadas 99 variáveis candidatas a explicativas, distribuídas em quatro grupos principais:

Grupo	Quantidade	Características
Variáveis numéricas	20	Quantidades, taxas, indicadores e características de mercado
CONCENTRACAO_*	36	Variáveis ordinais relacionadas à concentração de estabelecimentos
DISTANCIA_*	39	Variáveis ordinais relacionadas à distância de pontos de referência
Variáveis nominais	4	SECAO_CNAE, CATEGORIA_NATUREZA_JURIDICA, PORTE e PORTE_FATURAMENTO_PRESUMIDO

5.1 Dados ausentes

A análise identificou 99 das 103 colunas com pelo menos um valor ausente. Portanto, os dados faltantes constituíram uma característica relevante da base e precisaram ser tratados antes da modelagem.


O tratamento adotado posteriormente diferenciou as variáveis de acordo com sua natureza:

variáveis numéricas: imputação pela média;

variáveis categóricas: criação de uma categoria específica para representar ausência (*ISMISSING*).

Essa abordagem permitiu preservar registros que poderiam ser descartados caso fosse adotada uma estratégia de exclusão de linhas.

Figura 1 - Top 20 colunas com mais valores ausentes



Fonte: O autor

5.2 Poder de predição

Para investigar quais variáveis apresentaram maior relação individual com *ALVO*, foram utilizados critérios diferentes de acordo com a natureza da variável.

Para as variáveis numéricas, foi utilizada a magnitude da correlação de Pearson com o alvo. Para as variáveis ordinais, foi calculada a amplitude da taxa de sinistro entre as categorias, considerando apenas categorias com pelo menos 30 observações.

Entre as variáveis numéricas, as maiores correlações observadas foram relativamente baixas. A variável com maior correlação foi *QTD_ABERTURAS_ESTADUAL_5_ANOS*, com aproximadamente 0,034.

Já entre as variáveis ordinais, foram identificadas relações mais expressivas. A variável *DISTANCIA_CINEMAS* apresentou a maior amplitude da taxa de sinistro, aproximadamente 0,237, seguida por *DISTANCIA_TREM* (0,230) e *DISTANCIA_PONTO_TAXI* (0,216).

Esse resultado indica que algumas características espaciais apresentaram maior capacidade de diferenciação individual do risco do que determinadas variáveis cadastrais ou de mercado.

5.3 Consistência temporal

A dimensão temporal foi considerada uma etapa importante da análise, uma vez que a utilização de dados recentes poderia produzir uma avaliação incorreta caso os sinistros ainda não estivessem completamente registrados.

Foram avaliadas duas possibilidades de divisão:

- Cenário A: treinamento com dados de 2019 e 2020 e teste com todo o ano de 2021;
- Cenário B: treinamento de janeiro de 2019 a setembro de 2020 e teste de outubro a dezembro de 2020.

No Cenário A, a taxa de sinistro foi de aproximadamente 27,8% no treinamento e 19,3% no teste, enquanto no Cenário B as taxas foram de 27,7% no treinamento e 28,5% no teste.

A diferença observada em 2021 levou à investigação de possíveis efeitos de Data Drift e Concept Drift e à hipótese de maturação incompleta dos dados de sinistro.

A análise complementar mostrou que o AUC do modelo permaneceu praticamente estável:

- Cenário B: AUC = 0,656
- Cenário A/2021: AUC = 0,657

Entretanto, o nível absoluto da taxa de sinistro em 2021 foi inferior nos diferentes decis. Isso indica que o score continuou capaz de ordenar o risco relativo, mas que a taxa observada em 2021 não deveria ser interpretada diretamente como probabilidade absoluta de sinistro enquanto o período ainda estivesse sujeito à maturação do rótulo.

6 Preparação dos Dados

6.1 Limpeza

Inicialmente, foram removidas as observações sem valor na variável ALVO, uma vez que o modelo supervisionado necessita de um rótulo conhecido para o treinamento e avaliação.

O CNPJ, apesar de ser utilizado para verificar a presença da mesma empresa em diferentes períodos, não foi utilizado como variável explicativa. Dessa forma, evitou-se que o identificador anonimizado fosse utilizado diretamente pelo modelo.

Também foram excluídas da entrada do modelo as variáveis temporais utilizadas exclusivamente para organização e controle da divisão da base.

6.2 Tratamento

O tratamento foi direcionado principalmente aos valores ausentes encontrados na base.

A análise inicial identificou valores ausentes em grande parte das variáveis disponíveis. Para evitar a perda excessiva de registros, foi adotada uma estratégia de imputação diferenciada conforme o tipo da variável.

Para as variáveis numéricas, os valores ausentes foram substituídos pela média calculada no conjunto de treinamento.

Para as variáveis categóricas, os valores ausentes foram representados por uma categoria específica, denominada *ISMISSING*. Dessa forma, a ausência da informação foi preservada como uma característica da observação.

O tratamento foi incorporado ao pipeline de modelagem, garantindo que os parâmetros necessários para a transformação fossem obtidos a partir dos dados de treinamento.

6.3 Transformação

A transformação dos dados teve como objetivo adequar as diferentes representações das variáveis para que pudessem ser utilizadas pelo algoritmo.

As variáveis relacionadas às categorias de distância e concentração apresentavam valores textuais ordenados, como mostra na tabela abaixo:

Variáveis	Valor Atribuído
MUITO PROXIMO	1

PROXIMO	2
MEDIO	3
LONGE	4
MUITO LONGE	5

Essa transformação permitiu representar a ordem existente entre as categorias sem tratá-las como categorias completamente independentes.

As variáveis categóricas nominais também foram preparadas para utilização pelo modelo por meio das transformações definidas no pipeline.

6.4 Normalização

Não foi realizada normalização ou padronização das variáveis numéricas, devido ao algoritmo utilizado no projeto que foi o *Random Forest*. Como o modelo é baseado em árvores de decisão, a escala das variáveis não exerce o mesmo impacto observado em algoritmos baseados em distância ou em modelos que dependem diretamente da magnitude dos coeficientes.

Dessa forma, não houve necessidade de aplicar técnicas como *StandardScaler* ou *MinMaxScaler*.

A ausência de normalização também contribuiu para manter a interpretação original das variáveis numéricas durante o processo de modelagem.

6.5 Criação de variáveis

Durante a preparação dos dados foram criadas novas variáveis a partir de informações existentes na base.

Uma das variáveis criadas foi o *ANO*, obtido a partir da variável temporal *ANO_MES*. Essa informação foi utilizada principalmente para apoiar a análise temporal e a organização dos períodos de treinamento e teste.

Também foi criada a variável *QTD_COLABORADORES_FAIXA*, responsável por transformar a quantidade de colaboradores em categorias de porte operacional:

- SEM_COLABORADOR;
- MICRO_1_5;
- PEQUENA_6_20;
- MEDIA_21_100;
- GRANDE_100_MAIS.

Além disso, foram criadas variáveis agregadas relacionadas às características das empresas, como o *INDICADOR_ATRITO*, construído a partir da combinação da quantidade de reclamações e processos judiciais.

6.6 Engenharia de atributos

A engenharia de atributos teve como objetivo criar representações mais informativas a partir das variáveis existentes, buscando melhorar a capacidade do modelo de identificar padrões relacionados à ocorrência de sinistros.

Foram utilizadas principalmente três estratégias: indicador de atrito, índice de proximidade urbana, faixa de colaboradores.

- **Indicador de atrito**

O *INDICADOR_ATRITO* é calculado a partir da soma de: *QTD_RECLAMACOES_TOTAL* + *QTD_PROCESSOS_JUDICIAIS_REQUERIDO*

A variável busca sintetizar em um único indicador informações relacionadas ao histórico de reclamações e processos judiciais.

- **Índice de proximidade urbana**

O *INDICE_PROXIMIDADE_URBANA* refere-se da agregação das variáveis de distância selecionadas.

As categorias de distância foram previamente convertidas para uma escala ordinal de 1 a 5 e, posteriormente, agregadas para representar de maneira resumida o grau de proximidade da empresa em relação aos diferentes pontos de referência disponíveis na base.

- **Faixa de colaboradores**

A quantidade de colaboradores foi discretizada em faixas, permitindo representar o porte da empresa de forma categórica em vez de utilizar exclusivamente o valor absoluto. Essa transformação pode facilitar a identificação de comportamentos diferentes entre empresas de portes distintos.

7 Desenvolvimento da Solução

7.1 Estratégia adotada

A solução foi desenvolvida com base na metodologia CRISP-DM, contemplando as etapas de entendimento do negócio, entendimento dos dados, preparação dos dados, modelagem e avaliação.

O problema de negócio foi convertido em um problema de classificação supervisionada binária, utilizando a variável *ALVO* como variável resposta. Nessa classificação, *ALVO* = 1 representa a ocorrência de sinistro e *ALVO* = 0 representa a não ocorrência.

Inicialmente, foi realizada a análise exploratória da base para compreender sua estrutura, distribuição das variáveis, presença de dados ausentes, comportamento temporal e capacidade de diferenciação dos atributos em relação ao alvo. Em seguida, foram executadas as etapas de limpeza, tratamento, transformação, seleção de variáveis e engenharia de atributos.

Para evitar que informações futuras influenciassem o treinamento, foi adotada uma separação temporal entre as amostras. O conjunto de treinamento compreendeu o período de janeiro de 2019 a setembro de 2020, enquanto o conjunto de teste compreendeu outubro a dezembro de 2020.

Após a preparação, foi utilizado o algoritmo *Random Forest*, escolhido por sua capacidade de trabalhar com diferentes tipos de variáveis e capturar relações não lineares entre os atributos e a ocorrência de sinistros.

A seleção dos hiperparâmetros foi realizada utilizando *RandomizedSearchCV*, combinada com *TimeSeriesSplit*, mantendo a característica temporal durante a validação. O modelo otimizado utilizou 250 árvores, profundidade máxima de 10 e *min_samples_leaf* igual a 30.

Como resultado, o modelo produz um score entre 0 e 1, utilizado para ordenar as empresas de acordo com seu risco relativo de ocorrência de sinistro. Posteriormente, esse score foi avaliado por meio de métricas de discriminação e segmentação, incluindo *AUC-ROC*, *KS*, análise por decis e Lift, permitindo verificar seu potencial de utilização no processo de avaliação de risco da seguradora.


7.2 Ferramentas utilizadas

O desenvolvimento do projeto foi realizado baseado, principalmente, na linguagem Python e bibliotecas voltadas para análise dos dados, tratamentos dos dados, modelagem e avaliação dos resultados. Na tabela abaixo estão descritas as ferramentas utilizadas.

Ferramenta/Biblioteca	Aplicação no projeto
<i>Python</i>	Linguagem utilizada no desenvolvimento da solução
<i>Pandas</i>	Leitura, manipulação, limpeza e análise da base de dados
<i>NumPy</i>	Operações numéricas e manipulação de dados
<i>Matplotlib</i>	Construção de gráficos para análise e avaliação
<i>Seaborn</i>	Visualização exploratória dos dados
<i>Scikit-learn</i>	Pré-processamento, criação do pipeline, validação e modelagem
<i>Random Forest Classifier</i>	Algoritmo utilizado para a classificação do risco
<i>RandomizedSearchCV</i>	Busca e otimização dos hiperparâmetros
<i>TimeSeriesSplit</i>	Validação respeitando a ordem temporal dos dados
<i>ColumnTransformer</i>	Aplicação de transformações específicas conforme o tipo de variável

Pipeline	Organização das etapas de preparação e modelagem
----------	--

7.3 Arquitetura da solução



Fonte: O autor


8 Resultados

O modelo desenvolvido apresentou capacidade moderada de discriminação do risco de ocorrência de sinistros. No conjunto de teste, o AUC-ROC foi de 0,656, enquanto o KS foi de 0,250. A proximidade entre os resultados de treino (AUC = 0,662) e teste indica ausência de forte sobreajuste.

Métrica	Treino	Teste
AUC-ROC	0,662	0,656
KS	0,351	0,250


A análise por decis de risco demonstrou capacidade de ordenação das empresas. No primeiro decil, a taxa de sinistro foi de 13,8%, enquanto no décimo decil alcançou 56,7%, aproximadamente 1,99 vez a taxa média da carteira.

Figura 2 – Taxa de sinistros por decil de risco: apresenta a evolução da ocorrência de sinistros conforme aumenta o score atribuído pelo modelo.



Fonte: O autor

Figura 3 – Gráfico Lift por decil: evidencia a concentração de maior risco nos decis superiores, com lift de 1,99 no décimo decil.




Fonte: O autor

Como referência técnica inicial para segmentação, foi considerado o score médio de 0,694 do décimo decil. Esse valor deve ser utilizado como apoio à análise de subscrição, e não como critério automático de aceitação ou recusa.

A avaliação temporal também apresentou estabilidade na capacidade de ordenação: o AUC foi de 0,656 no período de teste oficial e 0,657 na avaliação de 2021. Entretanto, as taxas absolutas de sinistro foram menores em 2021, o que pode estar relacionado à maturação incompleta dos registros de sinistros.

Figura 4 – Comparação temporal do desempenho: apresenta a estabilidade do AUC e a diferença das taxas de sinistro entre o período de teste e 2021.



Fonte: O autor

De forma geral, os resultados indicam que o modelo pode ser utilizado como instrumento de segmentação relativa de risco, direcionando análises mais detalhadas para empresas classificadas nos decis superiores.

9 Insights

9.1 O que foi descoberto?

A análise mostrou que o modelo consegue diferenciar grupos de empresas com maior e menor propensão à ocorrência de sinistros. O décimo decil apresentou taxa de sinistro de 56,7%, contra 13,8% no primeiro decil, indicando concentração de risco nos grupos de maior score.

Também foi observada estabilidade temporal do poder de discriminação, com AUC de 0,656 no teste oficial e 0,657 em 2021. Entretanto, as taxas absolutas de sinistro foram menores em 2021, possivelmente devido à maturação incompleta dos registros.

9.2 Quais decisões poderiam ser tomadas?

O score pode apoiar a segmentação da carteira e a priorização da análise de subscrição, direcionando maior atenção às empresas classificadas nos decis superiores. Como referência inicial, o décimo decil apresentou score médio de 0,694, podendo ser utilizado para identificar casos que demandem análise mais detalhada. A definição de regras definitivas de aceitação, recusa ou precificação deve ser validada posteriormente com critérios técnicos e de negócio.

9.3 Quais oportunidades foram encontradas?

Os resultados indicam oportunidades para:

- priorizar análises de maior risco durante a subscrição;
- utilizar o score para segmentar a carteira;
- direcionar recursos operacionais para empresas com maior exposição potencial;
- aprimorar futuramente a precificação e gestão de risco;
- incorporar novas variáveis e dados históricos para aumentar a capacidade preditiva do modelo.

Os gráficos de decil, lift e estabilidade temporal reforçam essas oportunidades ao demonstrar a concentração do risco nos grupos de maior score.

10 Limitações

10.1 O que dificultou o projeto?

Entre as principais dificuldades esteve a interpretação inicial da variável-alvo, que apresentava valores binários sem uma definição clara. Esse ponto foi esclarecido durante a mentoria, permitindo compreender corretamente o significado do alvo.

Outro desafio foi o baixo poder preditivo individual das variáveis numéricas, cuja maior correlação com o alvo foi de apenas 0,034, dificultando a identificação inicial de padrões relevantes.

Também houve dificuldade em diferenciar Data Drift de Concept Drift. Após análises temporais, verificou-se que a redução das taxas de sinistro em 2021 estava mais relacionada

à maturação incompleta dos registros do que a uma mudança efetiva no comportamento de risco.

Durante a seleção das variáveis, foi identificado ainda um vazamento metodológico, pois o poder preditivo havia sido inicialmente calculado utilizando informações da base completa, incluindo o período de teste. O procedimento foi posteriormente corrigido, mas gerou retrabalho e reforçou a necessidade de maior rigor na separação entre treinamento e teste.

Por fim, a pouca experiência inicial com técnicas de análise de dados e o conhecimento limitado sobre o mercado de seguros exigiram momentos de capacitação técnica e compartilhamento de conhecimento de negócio.

10.2 Quais melhorias poderiam ser feitas?

Como melhoria do processo de modelagem, recomenda-se testar métodos mais eficientes de otimização de hiperparâmetros, como o *BayesSearchCV*, buscando configurações que possam melhorar o desempenho e reduzir possíveis sinais de sobreajuste.

Também é necessário aprimorar a avaliação do poder preditivo individual das variáveis, utilizando métricas específicas para cada tipo de dado:

- KS (*Kolmogorov-Smirnov*): avaliação do poder preditivo das variáveis numéricas;
- Total Variation: avaliação do poder preditivo das variáveis categóricas.

Essas análises podem contribuir para uma seleção de atributos mais robusta e para a identificação das variáveis que realmente agregam informação ao modelo.

11 Próximos Passos

Como evolução da solução, pretende-se:

- realizar uma nova otimização dos hiperparâmetros utilizando *BayesSearchCV*;
- calcular o KS individual das variáveis numéricas;
- calcular Total Variation para as variáveis categóricas;
- revisar e aprimorar a seleção de atributos a partir dessas métricas;

- testar novas configurações e algoritmos de classificação;
- acompanhar o desempenho do modelo em novos períodos, considerando a maturação dos registros de sinistros;
- validar os resultados com as áreas de negócio para avaliar a utilização do score na segmentação e análise de risco patrimonial.

Essas evoluções podem aumentar a capacidade preditiva da solução e fornecer maior segurança para sua utilização como apoio à tomada de decisão.

12 Referências

BREIMAN, L. Random forests. Machine Learning, v. 45, p. 5-32, 2001. DOI: <https://doi.org/10.1023/A:1010933404324>.

CHAPMAN, P. et al. CRISP-DM 1.0: step-by-step data mining guide. SPSS, 2000.

FAWCETT, T. An introduction to ROC analysis. Pattern Recognition Letters, v. 27, n. 8, p. 861-874, 2006. DOI: <https://doi.org/10.1016/j.patrec.2005.10.010>.

SCIKIT-LEARN. RandomForestClassifier. [S. l.]: Scikit-learn, [s. d.]. Disponível em: <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html>. Acesso em: 12 set. 2026.

SCIKIT-LEARN. Metrics and scoring: quantifying the quality of predictions. [S. l.]: Scikit-learn, [s. d.]. Disponível em: https://scikit-learn.org/stable/modules/model_evaluation.html. Acesso em: 12 set. 2026.

ZENG, G. A comparison study of computational methods of Kolmogorov-Smirnov statistic in credit scoring. Communications in Statistics - Simulation and Computation, v. 46, n. 10, p. 7744-7760, 2017.